

WEB CRAWLING

Amirhossein FathBayati



INTRODUCTION



Internet Live Stats



5,418,535,245

Internet Users in the world



1,978,389,678

Total number of Websites



130,098,966,646

Emails sent [today](#)



477,705,172

Pinterest active users



285,075,432

Skype calls [today](#)



117,374

Websites hacked [today](#)



4,142,717,008

Google searches [today](#)



4,037,179

Blog posts written [today](#)



399,665,931

Tweets sent [today](#)



299,275

Computers sold [today](#)



2,034,459

Smartphones sold [today](#)



167,760

Tablets sold [today](#)



3,828,417,121

Videos viewed [today](#)
on YouTube



46,643,658

Photos uploaded [today](#)
on Instagram



84,821,240

Tumblr posts [today](#)



6,334,973,138 GB

Internet traffic [today](#)



2,206,853 MWh

Electricity used [today](#)
for the Internet



1,695,980 tons

CO₂ emissions [today](#)
from the Internet



3,260,369,714

Facebook active users



1,169,480,746

Google+ active users



392,068,475

Twitter active users



GOOGLE AI'S GEMINI
RECEIVES
8,574 VISITORS

TIKTOK
USERS UPLOAD
16,000 VIDEOS

NETFLIX
SUBSCRIBERS
STREAMED
362,962
HOURS

PEOPLE DO
5.9M
GOOGLE
SEARCHES

SIRI
ANSWERS
1,041,666
QUESTIONS

18.8M
TEXT
MESSAGES
SENT

3,472,222
YOUTUBE
VIDEO VIEWS

138.9M
REELS PLAYED ON
FACEBOOK +
INSTAGRAM

251.1M
EMAILS
SENT

9,000
MEMBERS
APPLY FOR
JOBS ON
LINKEDIN

229M
MEETING MINUTES
RECORDED ON
MSFT
TEAMS

SNAPCHAT
USERS SEND
3.3M SNAPS

CYBER
WEEK
SHOPPERS
SPENT
\$43.6M
GLOBALLY

288
PEOPLE
DOWNLOAD
ZOOM





AMERICANS
TAKE
1,151,176,000
STEPS

DOORDASH
DINERS PLACE
\$126,763
IN ORDERS

FORTNITE
USERS WATCH
1,563 HOURS OF
LIVE STREAMS

4,080
RECORDS
COMPROMISED IN
DATA BREACHES


TRAVELERS BOOK
852 **AIRBNB**
STAYS



EARLY 1990S

تصور کنید در اوایل دهه 90 میلادی هستیم، زمانی که اینترنت هنوز یک پدیده نوظهور و نسبتاً ناشناخته بود. وبسایت‌ها انگشت‌شمار بودند و پیدا کردن اطلاعات مورد نیاز در این فضای جدید، کار دشواری به حساب می‌آمد. درست در همین زمان بود که ایده‌ای خلاقانه در ذهن چند برنامه‌نویس شکل گرفت: ساخت ابزاری خودکار برای کاوش در این دنیای نوپا و فهرست‌بندی وبسایت‌ها.

این ایده به تولد اولین خزنده‌های وب منجر شد. خزنده‌هایی ابتدایی اما کارآمد که مانند عنکبوت‌هایی کوچک، در تار عنکبوت وب به حرکت درمی‌آمدند و اطلاعات اولیه‌ای از وبسایت‌ها جمع‌آوری می‌کردند. WebCrawler و Aliweb از جمله پیشگامان این عرصه بودند.



MID AND LATE 90S

در سال 1994، WebCrawler به عنوان اولین موتور جستجوی تمام متن معرفی شد. این اتفاق نقطه‌ی عطفی در تاریخ اینترنت بود، زیرا برای اولین بار کاربران می‌توانستند با وارد کردن کلمات کلیدی، در میان محتوای صفحات وب جستجو کنند.

با گذشت زمان و با افزایش تعداد وبسایت‌ها، نیاز به موتورهای جستجوی پیشرفته‌تر و خزنده‌های قدرتمندتر احساس شد. در اواخر دهه 90، Googlebot ظهور کرد، خزنده وب متعلق به گوگل که با سرعت و دقت بالایی، اطلاعات وب را جمع‌آوری و فهرست‌بندی می‌کرد.



► Choose one of these categories:

[Arts & Literature](#) - [Business](#) - [Chat](#) - [Computers](#) - [Daily News](#)
[Education](#) - [Entertainment](#) - [Government](#) - [Health & Medicine](#)
[Internet](#) - [Kids & Families](#) - [Life & Culture](#) - [Personal Finance](#)
[Recreation](#) - [Reference Desk](#) - [Science](#) - [Sports](#) - [Travel](#)

Sites for Sports [News & Scores!](#)

Search [Browse](#) [Special](#) [Add URL](#) [Help](#)



Copyright © 1996 [America Online, Inc.](#)
[Disclaimer](#)

IN 2000S

در دهه 2000، خزنده‌های وب دیگر فقط برای فهرست‌بندی وب‌سایت‌ها استفاده نمی‌شدند. با توسعه تکنیک‌های استخراج محتوا، کاربردهای جدیدی برای این ابزارها تعریف شد. از جمله این کاربردها می‌توان به مقایسه قیمت محصولات در فروشگاه‌های آنلاین و جمع‌آوری اخبار از منابع مختلف اشاره کرد. امروزه، خزنده‌های وب به ابزاری حیاتی برای بسیاری از صنایع و تحقیقات تبدیل شده‌اند. از موتورهای جستجو و شبکه‌های اجتماعی گرفته تا شرکت‌های تجارت الکترونیک و موسسات تحقیقاتی، همگی از خزنده‌های وب برای جمع‌آوری، تجزیه و تحلیل اطلاعات استفاده می‌کنند.



SO WHAT IS WEB CRAWLER?

WEB SPIDER . BOT . WEB ROBOT



HOW IT WORKS?




ARCHITECTURE OF A WEB CRAWLER

URL Queue	Downloader	HTML Parser
Extractor	Duplicate Remover	Storage



CRAWLING MECHANISM



DATA EXTRACTION

?


HTML Parsing
Dom
Sax

Anti Crawling
User-Agent Spoofing
Rotating Proxies
CAPTCHA Solving
Headless Browsers

Element Section
Xpath
Css Selectors

Data management

Attributte Extraction




Link handling

CRAWLING POLICIES

انتخاب (Selection):

سوال کلیدی: "کدام صفحات وب برای ما مهمتر هستند و باید در اولویت قرار بگیرند؟"

مثال: اگر خزنده وب برای جمع‌آوری اخبار طراحی شده است، باید صفحاتی که حاوی اخبار جدید هستند را در اولویت قرار دهد.



ترتیب (Ordering)

سوال کلیدی: "به چه ترتیبی باید صفحات وب را بازدید کنیم؟"

توضیح: "خزنده وب باید تصمیم بگیرد که به چه ترتیبی URLها را از صف URLها انتخاب و بازدید کند. الگوریتم‌های مختلفی برای این منظور وجود دارند"



CRAWLING POLICIES

تکرار (Revisiting)

سوال کلیدی: "هر چند وقت یکبار باید صفحات وب را دوباره بازدید کنیم تا اطلاعات به روز را جمع‌آوری کنیم؟"


توضیح: "صفحات وب به طور مداوم در حال تغییر و به‌روزرسانی هستند. خزنده وب باید به طور دوره‌ای صفحات وب را دوباره بازدید کند تا اطلاعات جدید را جمع‌آوری و اطلاعات قدیمی را به‌روزرسانی کند. فاصله زمانی بین بازدیدها بستگی به نرخ تغییر صفحه و اهمیت اطلاعات موجود در صفحه دارد."

ادب (Politeness)

سوال کلیدی: "چگونه می‌توانیم به وبسایت‌ها احترام بگذاریم و از ایجاد مشکل برای آن‌ها جلوگیری کنیم؟"

توضیح: "خزنده وب باید به وبسایت‌ها احترام بگذارد و از ایجاد بار زیاد بر روی سرورهای آن‌ها جلوگیری کند. این کار با رعایت موارد زیر انجام می‌شود:"

رعایت فایل robots.txt
محدود کردن سرعت خزش
شناسایی خود







```

user-agent: *
disallow: /magnet/*
disallow: /users/*
disallow: /card
disallow: /shipping
disallow: /payment
disallow: /*?
disallow: /search?q=*
disallow: /profile*
disallow: *utm_*
disallow: /product/comment/*
disallow: /rss
disallow: /services
disallow: /temp
disallow: /testservice
disallow: /upload
disallow: /web%20references
disallow: /bin-copy
disallow: /*product/dkpi-*
  
```



FAMOUS CRAWLERS



CODE

THANK YOU FOR LISTENING!

Sources:

The Web Scraping Wikipedia Page: (https://en.wikipedia.org/wiki/Web_scraping)

ACM Transactions on the Web: (<https://dl.acm.org/journal/tweb>)

How to Build a Web Crawler from Scratch: (<https://www.promptapi.com/blog/how-to-build-a-web-crawler-from-scratch>)

Web crawler: (https://en.wikipedia.org/wiki/Web_crawler)

Zyte (formerly Scrapinghub) Blog: (<https://www.zyte.com/blog/>)